

Programación para la ciencia de datos

ACVs ANALISIS PREDICTIVO

Integrantes:
Mauricio Tapia
Tomas Zapata
Gabriel Muñoz




Profesor:
Victor Trigo
Sección:
001D

Problema y Objetivos

- Objetivo: Identificar probabilidades y/o desencadenantes de sufrir un accidente cerebrovascular.
- Problema: Datos de salud reales presentan desbalance de clases, valores nulos y ruido clínico (Unknowns).
- Objetivo General: Implementar un Pipeline modular y reproducible para transformar datos crudos en un dataset listo para Machine Learning.




Distribución de la Variable Stroke (Ataque cerebrovascular)



EDA - Diagnostico de desbalance.

- Variable Objetivo (stroke): Desbalance crítico. Solo el 4.9% ha sufrido un ACV.
- Justificación: Esto obliga a enfocarse en métricas de Sensibilidad más que en precisión general.

Matriz de Correlación - Variables Numéricas (Stroke)




EDA - Hallazgos y correlaciones.

- Factores Clave: La edad es el predictor principal (0.25).
- Riesgos: Glucosa >200 mg/dL e hipertensión presentan una correlación directa con casos positivos.

Calidad de datos (Diagnóstico técnico).

- Valores Nulos: Detectados en bmi.
- Categoría Unknown: En fumadores, se identificó que "Unknown" no aporta información clínica y debe tratarse como nulo para su imputación.
- Outliers: Valores extremos en BMI y Glucosa que pueden sesgar modelos lineales.



Metodología de Transformación


- Imputación: Uso de la mediana para BMI y Glucosa (Justificación: robustez ante valores extremos).
- Tratamiento de "Unknown": Re-clasificación lógica para recuperar la utilidad estadística del dato.
- Estandarización: Escalado de datos numéricos para que todas las variables tengan el mismo peso matemático.

Gestión de Outliers y Arquitectura de Pipeline


Tratamiento de Atípicos: Se detectaron valores extremos en Glucosa y BMI. Se aplica Capping (acotado) en percentiles para mantener la señal de riesgo sin distorsionar la convergencia del algoritmo.




Box plot de age




Box plot de hypertension




Box plot de heart_disease




Box plot de avg_glucose_level



Box plot de bmi



Box plot de stroke




INTEGRIDAD Y AUDITORÍA DE DATOS

- Estructura de Proyecto: Organización profesional de directorios (/data, /src, /outputs) según estándares de la industria.
- Checksums (MD5): garantizan integridad del dataset procesado
- Entorno virtual + requirements.txt: reproducibilidad en cualquier máquina



```
✓ EDA-ACV
  ✓ data
    ✓ processed
      processed_data.csv
    ✓ raw
      healthcare-dataset-stroke-data.csv
  ✓ docs
    Análisis Predictivo en Accidentes Cerebrovascul...
  ✓ notebooks
    02_Pipelines.ipynb
    eda.ipynb
  ✓ outputs
    > graficos
    {} audit_log.json
  ✓ src
    > __pycache__
    __init__.py
    audit.py
    optimization.py
    pipeline.py
    transformers.py
  .gitignore
  main.py
  {} metadata.json
  README.md
  requirements.txt
```

ARQUITECTURA DEL PIPELINE DE PREPROCESAMIENTO




RESULTADOS E INSIGHTS CLAVE

- Insight 1: El riesgo de ACV se dispara exponencialmente después de los 60 años.
- Insight 2: Los pacientes con niveles de glucosa superiores a 200 mg/dL muestran una densidad de casos significativamente mayor.
- Resultado: Tras la limpieza, el dataset mantiene la representatividad clínica pero sin ruidos técnicos.



RESULTADOS E INSIGHTS CLAVE



ANALISIS ESTADISTICO GENERAL

- Edad: mayor incidencia de ACV en adultos mayores
- IMC: >30 aumenta riesgo de ACV
- Hipertensión y glucosa elevada: correlacionan con mayor probabilidad de ACV

CONCLUSIONES Y FUTURO

- Dataset limpio y listo para ML
- Autocrítica: faltan variables clínicas como antecedentes familiares
- Futuro: técnicas de balanceo (SMOTE) y modelos predictivos



GRACIAS POR VER

Github:

<https://github.com/MauricioTapia84/EDA-ACV/tree/main>

Database:

<https://www.kaggle.com/datasets/fedesorianol/stroke-prediction-dataset>